

Tugas 7: Praktikum Mandiri 7 Machine Learning

Hisyam Wildan Alfath - 0110222206

Teknik Informatika, STT Terpadu Nurul Fikri, Depok

E-mail: hisyy22206ti@student.nurulfikri.ac.id

Abstract. Praktikum mandiri ini bertujuan untuk mempelajari penerapan Regresi Linear dalam memprediksi kandungan Nitrogen (N) menggunakan data satelit. Kegiatan mencakup proses pembersihan data, penanganan nilai hilang, pembagian data menjadi data latih dan uji, serta evaluasi kinerja model menggunakan metrik R^2 , MAE, dan RMSE. Hasil menunjukkan bahwa model mampu memprediksi nilai Nitrogen dengan baik, dengan nilai R^2 sebesar 0.755, yang menandakan tingkat akurasi yang cukup tinggi dan kesalahan prediksi yang rendah.

1. Praktikum Mandiri 07

- Menghubungkan Colab dengan Google Drive

```
[1]
✓ 20s
# Menghubungkan colab dengan google drive
from google.colab import drive
drive.mount('/content/drive')

Mounted at /content/drive
```

Kode ini memanggil modul drive dari google.colab untuk menghubungkan (mount) Google Drive ke lingkungan Google Colab, dan outputnya adalah muncul pesan “Mounted at /content/drive” yang menandakan folder Google Drive sekarang sudah bisa diakses pada path tersebut di Colab.

- Mengonversi dan Membersihkan Data CSV

```
import pandas as pd

# Membaca file csv menggunakan pandas
df = pd.read_csv("/content/drive/MyDrive/Hisyam Wildan Alfath/Semester 7/Machine Learning/Pertemuan 7/Praktikum dan Tugas Mandiri 07/data/dataset_satelit.csv")

# Convert 'Hg' column to numeric, coercing errors
df['Hg'] = pd.to_numeric(df['Hg'], errors='coerce')

# Fill any resulting NaN values in 'Hg' with the mean
df['Hg'].fillna(df['Hg'].mean(), inplace=True)

# Cetak header data (5 baris data) dari file
display(df.head())

/tmp/ipython-input-451430351.py:18: FutureWarning: A value is trying to be set on a copy of a DataFrame or Series through chained assignment using an inplace method.
The behavior will change in pandas 3.0. This inplace method will never work because the intermediate object on which we are setting values always behaves as a copy.
For example, when doing 'df[col].method(value, inplace=True)', try using 'df.method({col: value}, inplace=True)' or df[col] = df[col].method(value) instead, to perform the operation inplace on the original object.


df['Hg'].fillna(df['Hg'].mean(), inplace=True)

  No  Longitude  Latitude  N  P  K  Ca  Mg  Fe  Mn  ...  bi  Sigma_W  Sigma_Wt  pla  lia  iafe  gamma0_vv  gamma0_vh  beta0_vv  beta0_vh
0  1  103.036658  -0.604417  2.64  0.15  0.415  0.51  0.31  119.96  463.23  ...  0.0433  0.18183  0.04461  35.74446  35.79744  35.41161  0.22331  0.05479  0.31325  0.07686
1  2  103.037201  -0.604689  2.75  0.17  0.568  0.76  0.58  102.63  493.81  ...  0.0465  0.22079  0.04640  35.12096  35.14591  35.41510  0.27116  0.05699  0.38033  0.07993
2  3  103.036399  -0.603012  1.77  0.12  0.339  0.49  0.60  107.37  460.93  ...  0.0417  0.18926  0.03992  35.07724  35.07730  35.41135  0.23242  0.04902  0.32604  0.06876
3  4  103.036360  -0.603219  2.30  0.15  0.460  0.74  0.67  96.02  338.17  ...  0.0367  0.14769  0.03622  36.08078  36.08469  35.41583  0.18138  0.04448  0.25440  0.06238
4  5  103.036802  -0.601969  2.05  0.14  0.308  0.64  0.72  87.01  384.33  ...  0.0361  0.18205  0.03797  32.68855  32.69293  35.41592  0.22359  0.04664  0.31359  0.06541

5 rows x 34 columns
```

Kode pada gambar digunakan untuk membaca file data berformat CSV menggunakan library pandas, kemudian melakukan pembersihan data pada kolom 'Mg'. Pertama, file dataset_satelit.csv dibaca menggunakan fungsi `pd.read_csv()` dan disimpan dalam DataFrame. Selanjutnya, kolom 'Mg' dikonversi menjadi numerik dengan `pd.to_numeric()` agar data non-angka diubah menjadi NaN. Nilai kosong tersebut kemudian diisi dengan rata-rata kolom menggunakan `fillna()`. Terakhir, fungsi `df.head()` digunakan untuk menampilkan lima baris pertama sebagai pengecekan bahwa data berhasil dibaca dan dibersihkan dengan benar.

- Menampilkan Informasi Struktur DataFrame



```
[3]: df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 594 entries, 0 to 593
Data columns (total 34 columns):
#   Column      Non-Null Count  Dtype
---  -
0    No          594 non-null    int64
1    Longitude   594 non-null    float64
2    Latitude    594 non-null    float64
3    N            594 non-null    float64
4    P            594 non-null    float64
5    K            593 non-null    float64
6    Ca           594 non-null    float64
7    Mg           594 non-null    float64
8    Fe           594 non-null    float64
9    Mn           594 non-null    float64
10   Cu           594 non-null    float64
11   Zn           594 non-null    float64
12   B            594 non-null    float64
13   b12          594 non-null    float64
14   b11          594 non-null    float64
15   b9           594 non-null    float64
16   b8a          594 non-null    float64
17   b8           594 non-null    float64
18   b7           594 non-null    float64
19   b6           594 non-null    float64
20   b5           594 non-null    float64
21   b4           594 non-null    float64
22   b3           594 non-null    float64
23   b2           594 non-null    float64
24   b1           594 non-null    float64
25   Sigma_VV    594 non-null    float64
26   Sigma_VH    594 non-null    float64
27   plia        594 non-null    float64
28   lia         594 non-null    float64
29   iafe        594 non-null    float64
30   gamma0_vv   594 non-null    float64
31   gamma0_vh   594 non-null    float64
32   beta0_vv    594 non-null    float64
33   beta0_vh    594 non-null    float64
dtypes: float64(33), int64(1)
memory usage: 157.9 KB
```

Kode pada gambar digunakan untuk menampilkan informasi lengkap mengenai struktur DataFrame menggunakan fungsi `df.info()`. Perintah ini memberikan ringkasan data seperti jumlah baris, jumlah kolom, nama setiap kolom, jumlah nilai non-null, serta tipe data pada masing-masing kolom. Dari hasil output terlihat bahwa DataFrame memiliki 594 baris dan 34 kolom, dengan sebagian besar kolom bertipe float64 dan satu kolom bertipe int64. Informasi ini berguna untuk mengetahui apakah terdapat data

yang hilang (null) dan memastikan tipe data sudah sesuai sebelum dilakukan analisis lebih lanjut.

- Menampilkan Statistik Deskriptif Data

```
[4]
✓ Os
df.describe()
```

	No	Longitude	Latitude	N	P	K	Ca	Mg	Fe	Mn	...
count	594.000000	594.000000	594.000000	594.000000	594.000000	593.000000	594.000000	594.000000	594.000000	594.000000	...
mean	297.500000	106.878644	-1.024933	2.259091	0.141380	0.582175	0.595094	0.558331	74.613771	308.034697	...
std	171.617307	4.949840	0.965349	0.395499	0.019782	0.222567	0.366118	0.149252	55.579655	241.731643	...
min	1.000000	102.760857	-2.333750	1.140000	0.090000	0.122000	0.050000	0.210000	21.080000	3.160000	...
25%	149.250000	102.927811	-2.233338	1.982500	0.130000	0.429000	0.320000	0.460000	40.705000	124.015000	...
50%	297.500000	103.581969	-0.602276	2.280000	0.140000	0.549000	0.540000	0.550000	65.650000	239.445000	...
75%	445.750000	113.403797	-0.257349	2.570000	0.150000	0.710000	0.790000	0.650000	87.372500	434.990000	...
max	594.000000	113.434700	0.069251	3.230000	0.220000	1.489000	2.820000	1.080000	559.100000	2009.320000	...

8 rows x 34 columns

Kode pada gambar digunakan untuk menampilkan statistik deskriptif dari setiap kolom numerik dalam DataFrame menggunakan fungsi `df.describe()`. Perintah ini menghasilkan ringkasan statistik seperti jumlah data (`count`), nilai rata-rata (`mean`), standar deviasi (`std`), nilai minimum (`min`), kuartil (`25%`, `50%`, `75%`), dan nilai maksimum (`max`). Hasilnya menunjukkan bahwa dataset memiliki 594 baris dan 34 kolom, dengan setiap kolom menampilkan karakteristik nilai masing-masing. Informasi ini membantu pengguna memahami distribusi data, kisaran nilai, serta mendeteksi kemungkinan adanya nilai ekstrem atau outlier sebelum melakukan analisis lebih lanjut.

- Mengecek Data Duplikat

```
[5]
✓ Os
# Cek duplicate
df.duplicated().sum()

np.int64(0)
```

Kode pada gambar digunakan untuk memeriksa apakah terdapat data yang duplikat dalam DataFrame dengan menggunakan fungsi `df.duplicated().sum()`. Fungsi `duplicated()` akan mengembalikan nilai `True` untuk setiap baris yang terdeteksi sebagai duplikat, sedangkan fungsi `sum()` menghitung jumlah totalnya. Hasil yang ditampilkan adalah 0, yang berarti tidak ada data duplikat dalam dataset. Dengan demikian, dapat disimpulkan bahwa setiap baris data bersifat unik dan tidak memerlukan proses penghapusan duplikasi sebelum analisis dilakukan.

- Mengecek Nilai yang Hilang (Missing Values)

```
[6]
✓ Os # Check for missing values before filling
      print("Missing values before filling:")
      display(df.isnull().sum())

Missing values before filling:
0
No      0
Longitude 0
Latitude 0
N        0
P        0
K        1
Ca       0
Mg       0
Fe       0
Mn       0
Cu       0
Zn       0
B        0
b12     0
```

Kode pada gambar digunakan untuk memeriksa apakah terdapat nilai yang hilang atau missing values dalam dataset dengan menggunakan fungsi `df.isnull().sum()`. Fungsi `isnull()` akan mendeteksi nilai kosong (NaN) pada setiap kolom, sedangkan `sum()` menghitung jumlah total nilai kosong tersebut. Hasil yang ditampilkan menunjukkan bahwa hampir semua kolom tidak memiliki nilai yang hilang, kecuali kolom 'K' yang memiliki 1 nilai kosong. Langkah ini penting dilakukan sebelum proses pembersihan data agar pengguna mengetahui bagian mana dari dataset yang perlu diperbaiki atau diisi.

- Mengisi Nilai yang Hilang dengan Rata-Rata Kolom


```
[7]
✓ Os # Fill missing value in 'K' column with the mean
      df['K'].fillna(df['K'].mean(), inplace=True)

/tmp/ipython-input-2247185354.py:2: FutureWarning: A value is trying to be set on a copy of a DataFrame or Series through chained assignment using an inplace method.
The behavior will change in pandas 3.0. This inplace method will never work because the intermediate object on which we are setting values always behaves as a copy.
For example, when doing 'df[col].method(value, inplace=True)', try using 'df.method({col: value}, inplace=True)' or 'df[col] = df[col].method(value)' instead, to perform
df['K'].fillna(df['K'].mean(), inplace=True)
```

Kode pada gambar digunakan untuk mengisi nilai yang hilang pada kolom 'K' dengan nilai rata-rata menggunakan fungsi `fillna()`. Perintah `df['K'].fillna(df['K'].mean(), inplace=True)` berarti setiap nilai kosong pada kolom 'K' akan diganti dengan rata-rata dari kolom tersebut, sehingga tidak ada lagi data yang hilang. Namun, muncul peringatan (FutureWarning) yang menunjukkan bahwa penggunaan `inplace=True` dalam penugasan berantai akan berubah pada versi pandas

berikutnya. Oleh karena itu, disarankan untuk menulisnya dengan cara yang lebih aman, seperti `df['K'] = df['K'].fillna(df['K'].mean())`. Langkah ini penting untuk memastikan dataset bersih dan siap digunakan dalam proses analisis selanjutnya.

- Mengecek Nilai yang Hilang Setelah Pengisian




```
[8]
✓ Os # Check for missing values after filling
      print("Missing values after filling:")
      display(df.isnull().sum())

Missing values after filling:
      0
No      0
Longitude  0
Latitude  0
N      0
P      0
K      0
Ca      0
Mg      0
Fe      0
Mn      0
Cu      0
Zn      0
```

Kode pada gambar digunakan untuk memastikan bahwa tidak ada lagi nilai yang hilang (missing values) setelah proses pengisian data dilakukan. Fungsi `df.isnull().sum()` kembali digunakan untuk menghitung jumlah nilai kosong di setiap kolom, dan hasilnya menunjukkan bahwa seluruh kolom memiliki nilai 0, termasuk kolom 'K' yang sebelumnya memiliki satu nilai kosong. Hal ini berarti proses pengisian menggunakan nilai rata-rata telah berhasil, dan dataset kini bersih serta siap digunakan untuk analisis lebih lanjut tanpa adanya data yang hilang.

- Menampilkan Nama-Nama Kolom dalam DataFrame



```
[9]
✓ Os df.columns

Index(['No', 'Longitude', 'Latitude', 'N', 'P', 'K', 'Ca', 'Mg', 'Fe', 'Mn',
      'Cu', 'Zn', 'B', 'b12', 'b11', 'b9', 'b8a', 'b8', 'b7', 'b6', 'b5',
      'b4', 'b3', 'b2', 'b1', 'Sigma_VV', 'Sigma_VH', 'plia', 'lia', 'iafe',
      'gamma0_vv', 'gamma0_vh', 'beta0_vv', 'beta0_vh'],
      dtype='object')
```

Kode pada gambar digunakan untuk menampilkan seluruh nama kolom yang terdapat di dalam DataFrame dengan menggunakan atribut `df.columns`. Perintah ini menghasilkan daftar lengkap nama kolom dalam bentuk objek Index, yang

menunjukkan struktur data serta urutan setiap kolom. Hasilnya menampilkan kolom seperti No, Longitude, Latitude, N, P, K, Ca, Mg, Fe, dan lainnya hingga beta0_vh. Dengan cara ini, pengguna dapat mengetahui kolom apa saja yang tersedia dalam dataset, sehingga memudahkan dalam proses analisis atau pemilihan variabel yang akan digunakan selanjutnya.

- Membagi Dataset Menjadi Data Latih dan Data Uji

```
[17]
✓ 0s
from sklearn.model_selection import train_test_split

# Use the cleaned DataFrame for splitting
X = df[['P', 'K', 'Ca', 'Mg', 'Fe', 'Mn',
        'Cu', 'Zn', 'B', 'b12', 'b11', 'b9', 'b8a', 'b8', 'b7', 'b6', 'b5',
        'b4', 'b3', 'b2', 'b1', 'Sigma_VV', 'Sigma_VH', 'plia', 'lia', 'iafe',
        'gamma0_vv', 'gamma0_vh', 'beta0_vv', 'beta0_vh']]
y = df["N"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=7
)
```

Kode pada gambar digunakan untuk membagi dataset menjadi dua bagian, yaitu data latih (training data) dan data uji (testing data) menggunakan fungsi `train_test_split` dari modul `scikit-learn`. Variabel `X` berisi kumpulan fitur atau variabel independen seperti `P`, `K`, `Ca`, `Mg`, `Fe`, `Mn`, dan kolom lainnya yang digunakan sebagai input untuk model, sedangkan variabel `y` berisi kolom 'N' sebagai variabel target yang akan diprediksi.

Fungsi `train_test_split(X, y, test_size=0.2, random_state=7)` digunakan untuk memisahkan data dengan proporsi 80% untuk pelatihan dan 20% untuk pengujian, serta menggunakan `random_state=7` agar hasil pembagian data tetap konsisten setiap kali dijalankan. Langkah ini penting untuk mempersiapkan dataset sebelum digunakan dalam proses pelatihan dan evaluasi model machine learning.

- Membuat dan Melatih Model Regresi Linear

```
[18]
✓ 0s
from sklearn.linear_model import LinearRegression

model = LinearRegression()
model.fit(X_train, y_train)
```

LinearRegression ⓘ ⓘ
LinearRegression()

Kode pada gambar digunakan untuk membuat dan melatih model Regresi Linear menggunakan library scikit-learn. Pertama, modul LinearRegression diimpor dari sklearn.linear_model. Selanjutnya, objek model dibuat dengan perintah model = LinearRegression(). Kemudian, model tersebut dilatih menggunakan data latih (X_train dan y_train) melalui fungsi fit(). Proses ini bertujuan untuk membuat model mempelajari hubungan antara variabel input (fitur) dan variabel target, sehingga nantinya dapat digunakan untuk memprediksi nilai 'N' berdasarkan fitur-fitur lainnya dalam dataset.

- Evaluasi Model Regresi Linear

```
[20]
✓ Os
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_absolute_error, mean_squared_error

# Asumsikan kamu sudah punya model:
# model = LinearRegression().fit(X_train, y_train)
# dan sudah ada X_test, y_test

# Prediksi nilai N
y_pred = model.predict(X_test)

# Evaluasi model regresi
r2 = r2_score(y_test, y_pred)
mae = mean_absolute_error(y_test, y_pred)
mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)

# Cetak hasil evaluasi
print("Koefisien model (pengaruh tiap fitur):")
for name, coef in zip(X_train.columns, model.coef_):
    print(f" {name:>12}: {coef:.6f}")

print("\nIntersep (bias):", round(model.intercept_, 6))
print("R² (test):", round(r2, 4))
print("MAE:", round(mae, 4))
print("RMSE:", round(rmse, 4))
```

Kode pada gambar digunakan untuk melakukan prediksi dan evaluasi kinerja model Regresi Linear menggunakan metrik statistik. Pertama, model yang sudah dilatih digunakan untuk memprediksi nilai 'N' pada data uji dengan perintah y_pred = model.predict(X_test). Setelah itu, performa model dievaluasi menggunakan beberapa metrik, yaitu:

- R^2 Score (r2_score) untuk mengukur seberapa baik model menjelaskan variasi data.

- MAE (mean_absolute_error) untuk menghitung rata-rata selisih absolut antara nilai sebenarnya dan hasil prediksi.
- MSE (mean_squared_error) untuk menghitung rata-rata kesalahan kuadrat.
- RMSE (akar dari MSE) untuk memberikan ukuran kesalahan dalam satuan yang sama dengan data aslinya.

Selain itu, kode juga mencetak koefisien regresi (pengaruh masing-masing fitur terhadap target) serta intersep (bias) model. Output yang dihasilkan nantinya akan menampilkan daftar nama fitur beserta nilai koefisiennya, nilai intersep, serta hasil evaluasi berupa R^2 , MAE, MSE, dan RMSE, yang memberikan gambaran seberapa akurat model dalam memprediksi nilai 'N'.

- Hasil Evaluasi Model Regresi Linear

```
Koefisien model (pengaruh tiap fitur):
P: 8.412678
K: 0.040963
Ca: -0.057793
Mg: -0.230021
Fe: 0.000301
Mn: 0.000205
Cu: 0.026408
Zn: 0.002236
B: -0.001748
b12: 1.134855
b11: -1.380487
b9: -0.029835
b8a: 0.048781
b8: -0.073550
b7: 1.831329
b6: -1.505135
b5: -1.049204
b4: 0.878155
b3: 0.694377
b2: -0.805656
b1: 0.171881
Sigma_VV: -0.393130
Sigma_VH: -0.439051
plia: 0.041903
lia: -0.040916
iafe: -0.072221
gamma0_vv: -0.786456
gamma0_vh: 6.471816
beta0_vv: 0.770082
beta0_vh: -3.621204

Intersep (bias):      3.516331
R² (test):           0.7545
MAE:                 0.1624
RMSE:                0.2027
```

Output pada gambar menunjukkan hasil evaluasi dari model Regresi Linear yang telah dilatih untuk memprediksi nilai 'N' berdasarkan berbagai fitur input. Bagian pertama menampilkan koefisien model, yaitu pengaruh masing-masing variabel terhadap nilai prediksi. Nilai positif pada koefisien menunjukkan bahwa peningkatan

variabel tersebut akan meningkatkan nilai 'N', sedangkan nilai negatif menunjukkan pengaruh sebaliknya.

Selain itu, nilai intersep (bias) sebesar 3.516331 menunjukkan titik potong garis regresi ketika semua variabel input bernilai nol. Hasil evaluasi model juga ditampilkan melalui beberapa metrik, yaitu:

- R^2 (test) = 0.7545, menandakan bahwa sekitar 75,45% variasi data dapat dijelaskan oleh model.
- MAE = 0.1624, yang berarti rata-rata kesalahan prediksi model sekitar 0.16 satuan dari nilai sebenarnya.
- RMSE = 0.2027, menunjukkan akar dari rata-rata kesalahan kuadrat model.

Secara keseluruhan, nilai evaluasi tersebut menunjukkan bahwa model memiliki kinerja yang cukup baik dalam memprediksi nilai 'N', dengan tingkat kesalahan yang relatif rendah.

- Visualisasi Perbandingan Nilai Aktual dan Prediksi

```
[14]
✓ Os
# Scatter plot antara nilai aktual dan prediksi
import matplotlib.pyplot as plt


plt.figure(figsize=(6,6))
plt.scatter(y_test, y_pred, color='purple', alpha=0.7)
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], 'r--', lw=2)

plt.xlabel("Nilai Aktual Nitrogen (N)")
plt.ylabel("Nilai Prediksi Nitrogen (N)")
plt.title("Perbandingan Prediksi vs Nilai Aktual (Model Regresi)")

plt.text(
    0.05, 0.9,
    f"$R^2$ = {r2:.3f}\nRMSE = {rmse:.3f}\nMAE = {mae:.3f}",
    transform=plt.gca().transAxes, va="top"
)
plt.tight_layout()
plt.show()
```

Kode pada gambar digunakan untuk menampilkan **scatter plot** antara nilai aktual dan nilai prediksi dari model regresi linear. Titik berwarna ungu menunjukkan hubungan antara hasil prediksi dan nilai sebenarnya, sedangkan garis merah putus-putus menandakan garis ideal di mana prediksi sama dengan nilai aktual. Plot ini membantu melihat seberapa akurat model dalam memprediksi data — semakin dekat titik-titik ke garis merah, semakin baik performa model.

- Hasil Visualisasi Perbandingan Prediksi dan Nilai Aktual



Gambar di atas menunjukkan hasil scatter plot antara nilai aktual dan nilai prediksi dari model regresi linear. Titik berwarna ungu merepresentasikan hasil prediksi terhadap nilai sebenarnya, sedangkan garis merah putus-putus menunjukkan garis ideal di mana prediksi sama dengan data aktual. Nilai $R^2 = 0.755$, RMSE = 0.203, dan MAE = 0.162 menunjukkan bahwa model memiliki tingkat akurasi yang baik karena sebagian besar titik berada dekat dengan garis merah, menandakan hasil prediksi yang cukup sesuai dengan nilai sebenarnya.

- Kesimpulan

Setelah melakukan latihan mandiri ini, dapat disimpulkan bahwa model Regresi Linear mampu memprediksi nilai Nitrogen (N) dengan cukup baik. Data telah berhasil dibersihkan dan diuji, menghasilkan nilai R^2 sebesar 0.755, yang menunjukkan model memiliki tingkat akurasi tinggi dengan kesalahan prediksi yang kecil. Proses ini menunjukkan pentingnya pembersihan data dan evaluasi model dalam membangun prediksi yang andal.

Link Praktikum 07:

https://github.com/HisyamAlfath/ti03_hisyam_0110112001/blob/main/Pertemuan%207/Praktikum%20dan%20Tugas%20Mandiri%2007/notebooks/latihan07.ipynb

Tugas Mandiri 07:

https://github.com/HisyamAlfath/ti03_hisyam_0110112001/blob/main/Pertemuan%207/Praktikum%20dan%20Tugas%20Mandiri%2007/notebooks/latihan07.ipynb