


MACHINE LEARNING

K-Nearest Neighbours (KNN)

Dr. Sirojul Munir, S.Si., M.Kom.
rojulman@nurulfikri.ac.id

ARTIFICIAL INTELLIGENCE – INFORMATICS STTNF



Daur ulang Project Data Science



Algoritma Klasifikasi


1.K- Nearest Neighbors

2.Naive Bayes classifier

3.Decision Trees


4.Support Vector Machine

5.Random Forest




K-Nearest Neighbors (KNN)

- Algoritma klasifikasi berdasarkan dataset training yang diambil dari K tetangga terdekat (*Nearest Neighbors*)
- Termasuk dalam supervised learning, dimana hasil *query instance* yang baru di klasifikasikan berdasarkan mayoritas kedekatan jarak dari kategori yang ada dalam KNN
- Algoritma yang melakukan klasifikasi berdasarkan kedekatan jarak titik data dengan titik data lain



K-Nearest Neighbors


- Konsep dasar dari K-NN adalah mencari jarak terdekat antara data yang akan dievaluasi dengan K tetangga dalam data pelatihan
- Penghitungan jarak dilakukan dengan konsep euclidean
- Jumlah kelas yang paling banyak dengan jarak terdekat tersebut akan menjadi kelas dimana data kelas itu berada



- Jika $k=3$ maka lingkaran hijau akan masuk dalam kategori segitiga merah
- Jika $k=5$ maka lingkaran hijau akan masuk dalam kategori segiempat biru.


K-Nearest Neighbors (KNN)

1. Input data
2. Tentukan nilai K
3. Hitung jarak
4. Temukan tetangga terdekat
5. Voting: Tentukan label data




KNN Flowchart


- Penghitungan jarak didasarkan fungsi jarak (Euclidian, Manhattan, Minkowski)




- Jumlah class yang paling banyak dengan jarak terdekat tersebut akan menjadi kelas dimana data evaluasi berada



Contoh Implementasi KNN




Contoh Implementasi KNN



1. Input data : persegi warna orange
2. Tentukan nilai K : 5
3. Hitung jarak : fungsi euclidian
4. Temukan tetangga terdekat:
terdapat 2 kelas
Kategori A : warna hijau (3 titik terdekat)
Kategori B : warna biru (2 titik terdekat)
5. Voting - Tentukan label data: berdasarkan point 4, data masuk kategori A


Kelebihan KNN

- Kinerja yang baik untuk data simpel dan tidak terlalu banyak fitur
- Simpel dan mudah diimplementasikan karna prediksi dilakukan berdasarkan mayoritas label dari tetangga terdekat
- Bersifat Non-Parametrik: tidak ada asumsi tentang distribusi data, sehingga fleksibel dan dapat beradaptasi dengan berbagai jenis data
- ***Lazy Learner Algorithm***: tidak perlu proses training yang komplek
- Cocok untuk dataset yang kecil dan memiliki struktur data yang jelas
- KNN tidak sensitif terhadap perubahan data: tidak ada perubahan model ketika ada penambahan data



Kekurangan KNN

- Waktu komputasi yang tinggi jika dataset training besar, karena semua data akan diukur jarak terdekat dari data uji
- Sensitif terhadap data outlier
- Pemilihan K yang tepat dapat mempengaruhi kinerja KNN



Contoh Kasus 1: Klasifikasi Kualitas Tissue

Terdapat data hasil survei kuesioner **klasifikasi kualitas kertas tissue** apakah **baik** atau **jelek**, dengan objek training menggunakan dua atribut yaitu **daya tahan terhadap asam** dan **kekuatan**.
 Dengan menggunakan **K = 4**

Data Set (Training)

X1 = Daya tahan asam (detik)	X2 = Kekuatan (Kg/m ²)	Y = Klasifikasi
8	4	Baik
4	5	Jelek
4	6	Jelek
7	7	Baik
5	6	Jelek
6	5	Baik



Data Testing:

Akan diproduksi kembali kertas tisu dengan attribute X1=7 dan X2=4 tanpa harus mengeluarkan biaya untuk melakukan survey, maka dapat diklasifikasikan kertas tissue tersebut termasuk yang baik atau jelek !!

Contoh Kasus 1: Implementasi KNN



Step-1: Tentukan nilai $K = 4$

Step-2: Hitung jarak antara data yang akan di uji dengan semua data latih

X1 = Daya tahan asam (detik)	X2 = Kekuatan (kg/m²)	Square distance to query distance (7,4)
8	4	$(8-7)^2 + (4-4)^2 = 1$
4	5	$(4-7)^2 + (5-4)^2 = 10$
4	6	$(4-7)^2 + (6-4)^2 = 13$
7	7	$(7-7)^2 + (7-4)^2 = 9$
5	6	$(5-7)^2 + (6-4)^2 = 8$
6	5	$(6-7)^2 + (5-4)^2 = 2$

Contoh Kasus 1: Implementasi KNN

Step-3: Urutkan berdasarkan jarak terdekat (terkecil) dan, tentukan termasuk K-tetangga terdekat K = 4

X1= Daya tahan asam (detik)	X2= Kekuatan (Kg/m ²)	Square distance to query distance (7,4)	Jarak terkecil	Apakah termasuk nearest neighbor (K)	Y= kategori nearest neighbor
8	4	$(8-7)^2 + (4-4)^2 = 1$	1	Ya	Baik
4	5	$(4-7)^2 + (5-4)^2 = 10$	5	Tidak	-
4	6	$(4-7)^2 + (6-4)^2 = 13$	6	Tidak	-
7	7	$(7-7)^2 + (7-4)^2 = 9$	4	Ya	Baik
5	6	$(5-7)^2 + (6-4)^2 = 8$	3	Ya	Jelek
6	5	$(6-7)^2 + (5-4)^2 = 2$	2	Ya	Baik



Step-4: Terdapat k=4 pasangan terdekat: (8,4), (6,5), (5,6), (7,7)

Contoh Kasus 1: Implementasi KNN

Step-5: Temukan jumlah kelas terbanyak dari tetangga terdekat , dan hasil voting masukan data dalam kelas tersebut, didapat kelas terbanyak **baik = 3** dan **jelek = 1**, voting menghasilkan data uji ($x_1=7$, dan $x_2=4$) masuk kedalam kelas terbanyak yaitu kelas baik

Step-6: Hasil Evaluasi diperoleh tissue dengan daya tahan 7 dan Kekuatan 4 termasuk Kategori Baik



Evaluasi Model: Confusion Matrix

- Metode yang digunakan untuk evaluasi kinerja dari model klasifikasi
- Memberikan gambaran tentang seberapa baik model dalam memprediksi kelas dengan benar, dan seberapa besar kesalahan prediksi dalam klasifikasi
- Biasa digunakan untuk klasifikasi dengan lebih dari dua kelas

		Actual Class	
		1	0
Predicted Class	1	True Positive	False Positive
	0	False Negative	True Negative


Evaluasi Model: Confusion Matrix

- True Positive (TP): jumlah data positif yang terklasifikasi benar oleh sistem
- True Negative (TN): jumlah data negatif yang terklasifikasi benar oleh sistem
- False Negatif (FN): jumlah data negatif yang terklasifikasi salah oleh sistem
- False Positive (FP): jumlah data positif yang terklasifikasi salah oleh sistem


		Predicted	
		Negative (N) -	Positive (P) +
Actual	Negative -	True Negative (TN)	False Positive (FP) Type I Error
	Positive +	False Negative (FN) Type II Error	True Positive (TP)

Precision – Recall - Accuracy

- **Precision** adalah tingkat ketepatan antara informasi yang diminta oleh pengguna dengan jawaban yang diberikan oleh sistem.
- **Recall** adalah tingkat keberhasilan sistem dalam menemukan kembali sebuah informasi.
- **Accuracy** didefinisikan sebagai tingkat kedekatan antara nilai prediksi dengan nilai aktual



Precision – Recall - Accuracy



Confusion Matrix : Prediksi SPAM Email

Emails	Actual Classification	System (Predicted) Classification
Email 1	Spam	Spam
Email 2	Spam	Not Spam
Email 3	Not Spam	Not Spam
Email 4	Not Spam	Spam
Email 5	Not Spam	Spam
Email 6	Spam	Spam
Email 7	Spam	Not Spam
Email 8	Not Spam	Spam
Email 9	Spam	Spam
Email 10	Not Spam	Not Spam

... ..

100 data email

	Predicted Spam	Predicted Not Spam
Actual Spam	True Positive (TP) = 5	False Negative (FN) = 2
Actual Not Spam	False Positive (FP) = 1	True Negative (TN) = 92

1. Akurasi (Accuracy):

$$\text{Accuracy} = \frac{TP+TN}{TP+FP+FN+TN} = \frac{5+92}{5+1+2+92} = \frac{97}{100} = 0.97$$

2. Presisi (Precision):

$$\text{Precision} = \frac{TP}{TP+FP} = \frac{5}{5+1} = \frac{5}{6} \approx 0.83$$

3. Recall (Sensitivitas atau True Positive Rate):

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{5}{5+2} = \frac{5}{7} \approx 0.71$$

4. Specificity (True Negative Rate):

$$\text{Specificity} = \frac{TN}{TN+FP} = \frac{92}{92+1} = \frac{92}{93} \approx 0.99$$

5. F1-Score:

$$\text{F1-Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot 0.83 \cdot 0.71}{0.83 + 0.71} \approx 0.77$$

Latihan 1

Praktikum



Contoh berikut diambil dari buku “**Data Science Algorithms in a Week**” (oleh Dávid Natingga). Akan dilakukan klasifikasi suhu udara berdasarkan persepsi seseorang yang bernama Marry. Adapun klasifikasi suhu udara terdiri dari 2 persepsi yaitu **Panas** dan **Dingin**. Persepsi ini dapat diukur berdasarkan 2 variabel yaitu **temperatur dalam derajat celcius** dan **kecepatan angin dalam km/h**.

Data Set (raining)

Temperatur Udara (°C)	Kecepatan Angin (km/jam)	Klasifikasi atau Persepsi Marry
10	0	Dingin
25	0	Panas
15	5	Dingin
20	3	Panas
18	7	Dingin
20	10	Dingin
22	5	Panas
24	6	Panas

Data Test

- Bagaimana persepsi Marry saat temperatur udara 16°C dan kecepatan angin 3 km/jam ?
- Tentukan nilai k yang tepat berdasarkan akurasi yang paling baik

Latihan 2

Praktikum



Studi Kasus: Prediksi Kelulusan Matakuliah AI menggunakan model machine learning didapat hasil sebagai berikut:

Nim	Hasil Sebenarnya	Hasil Prediksi
TI001	Lulus	Lulus
TI002	Lulus	Lulus
TI003	Lulus	Lulus
TI004	Lulus	Tidak Lulus
TI005	Lulus	Tidak Lulus
TI006	Tidak Lulus	Lulus
TI007	Tidak Lulus	Tidak Lulus
TI008	Tidak Lulus	Tidak Lulus
TI009	Tidak Lulus	Tidak Lulus
TI010	Tidak Lulus	Tidak Lulus

1. Buat tabel confusion matrix berdasarkan tabel diatas
2. Hitung nilai persentase dari: *accuracy*, *precision* dan *recall*

Latihan 3

Praktikum

Studi Kasus: Gunakan KNN untuk prediksi Cuaca

	Temperature	Humidity	Wind Speed	Precipitation (%)	Cloud Cover	Atmospheric Pressure	UV Index	Season	Visibility (km)	Location	Weather Type
0	14.0	73	9.5	82.0	partly cloudy	1010.82	2	Winter	3.5	inland	Rainy
1	39.0	96	8.5	71.0	partly cloudy	1011.43	7	Spring	10.0	inland	Cloudy
2	30.0	64	7.0	16.0	clear	1018.72	5	Spring	5.5	mountain	Sunny
3	38.0	83	1.5	82.0	clear	1026.25	7	Spring	1.0	coastal	Sunny
4	27.0	74	17.0	66.0	overcast	990.67	1	Winter	2.5	mountain	Rainy
5	32.0	55	3.5	26.0	overcast	1010.03	2	Summer	5.0	inland	Cloudy
6	-2.0	97	8.0	86.0	overcast	990.87	1	Winter	4.0	inland	Snowy
7	3.0	85	6.0	96.0	partly cloudy	984.46	1	Winter	3.5	inland	Snowy
8	3.0	83	6.0	66.0	overcast	999.44	0	Winter	1.0	mountain	Snowy
9	28.0	74	8.5	107.0	clear	1012.13	8	Winter	7.5	coastal	Sunny



Terima Kasih

<http://youtube.com/@rojulman>